Machine learning e chatbot

A sustentabilidade financeira de um serviço de streaming depende estritamente da retenção, não apenas da aquisição. O modelo de negócios de receita recorrente entra em colapso lógico quando o índice de cancelamento de clientes supera a entrada de novos usuários. O custo de aquisição de cliente é pulverizado e resulta em prejuízo operacional imediato se o tempo de vida útil do usuário na plataforma for curto. O problema não é técnico, é de sobrevivência de fluxo de caixa.

Para investigar as raízes do cancelamento sem o ruído de bases genéricas da internet, isolamos o ambiente de testes. Forjamos uma base de dados sintética com mil registros utilizando um script em Python com lógica determinística embutida. Isso resolve a necessidade arquitetural de termos dados perfeitamente controlados. Ao controlarmos os pesos das variáveis na geração da base, garantimos que a futura validação da Inteligência Artificial prove a capacidade preditiva real do algoritmo, não um acaso estatístico.

Injetamos variáveis comportamentais críticas no histórico volume de horas assistidas por mês, incidência de atrasos de pagamento, volume de reclamações no suporte e ciclo de vida da assinatura.

A correlação causal é direta. O atraso em faturas sinaliza fricção de pagamento. O baixo volume de horas assistidas denuncia desengajamento agressivo com o catálogo. Clientes novos não possuem barreira de saída emocional e cancelam na primeira instabilidade sistêmica. O isolamento desses dados destrói a falácia de que o churn é imprevisível. O cancelamento não acontece no vácuo, ele é a etapa final de uma cadeia de eventos mapeáveis que deixa rastro óbvio no banco de dados.

Fontes: Data Science for Business - Predictive Modeling applied to Customer Retention

Impactos, Soluções e Engenharia de Retenção

O vazamento sistemático da base afeta os departamentos da organização de forma assimétrica. O setor Financeiro sofre o impacto central através da destruição da previsibilidade do fluxo de caixa e da erosão de margens de lucro. A área de Marketing perde a eficiência bruta do funil de conversão, pois o capital aportado em tráfego pago queima rapidamente sem tempo de amortização do custo de aquisição. A equipe de Produto é severamente punida com métricas enviesadas, gastando ciclos de desenvolvimento construindo funcionalidades para uma base irreal. O Churn não é um problema isolado de suporte ao usuário, é uma falha estrutural.

As soluções tradicionais do mercado esbarram em ações puramente reativas.

Disparar ofertas com descontos agressivos no exato segundo que o cliente clica no botão de cancelamento resolve a evasão temporária. O pró óbvio dessa tática é o estancamento da sangria imediata. O contra é a canibalização brutal da receita recorrente e a educação comportamental nociva da base, que rapidamente aprende a forjar o cancelamento em troca de vantagens financeiras.

Modelos preditivos quebram esse ciclo de reatividade e invertem a polaridade da estratégia comercial. O uso prático de algoritmos transforma a retenção em engenharia antecipada. Identificamos com precisão os usuários com alta probabilidade matemática de evasão semanas antes do evento ocorrer. Isso resolve o problema de timing da empresa. A campanha preventiva não precisa envolver subsídios financeiros, o time de client sucess opera com intervenções de baixo custo, como a recomendação técnica de conteúdos inexplorados no catálogo.

A execução técnica dessa solução colide inevitavelmente com a entropia da coleta de dados em sistemas em produção. Bases reais não são limpas. Sistemas consolidados misturam clientes legados de arquiteturas antigas com bases novas, resultando em silos granulares e formatos incompatíveis. Inconsistências sistêmicas e outliers contaminam a superfície de treinamento. Isso impede a extração e o uso cego do dado bruto. Se o pipeline não executar a normalização vetorial e o expurgo rigoroso dessas aberrações na etapa de pré-processamento, a capacidade preditiva do modelo implode em falsos positivos, inutilizando o projeto.

Fonte: IEEE Xplore - Predictive Modeling for Customer Retention in the Subscription Economy

A Arquitetura do Modelo e o Fluxo Prático

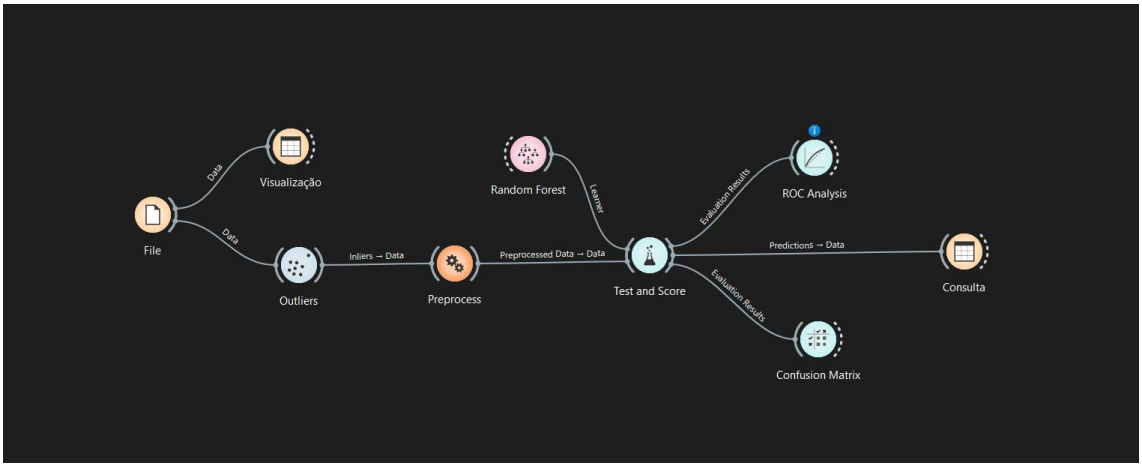
A essência preditiva deste projeto baseia-se nos pilares matemáticos de classificação e validação cruzada. Classificação é o mecanismo de forçar a máquina a separar os dados entrantes em categorias binárias estritas (cancelar ou não cancelar). Isso resolve a subjetividade de análises puramente humanas.

A validação cruzada certifica que o modelo treinado desenvolveu a capacidade de generalizar o aprendizado para cenários e usuários inéditos. Sem uma etapa rigorosa de validação, a alta precisão apontada pelo software é apenas uma armadilha estatística causada pela memorização da base de testes.

A arquitetura visual da solução foi implementada no **Orange Data Mining**. O fluxo inicia no componente File, que carrega o CSV do disco para a memória RAM. Sem isso, a injeção de dados falha logo na origem. O nó seguinte, Outliers, executa a varredura para isolar os registros atípicos. O expurgo dessas anomalias evita que o algoritmo force curvas matemáticas para se adaptar a falsos usuários, protegendo a coerência da rede neural subjacente.

O pré-processamento é consolidado no componente Preprocess via normalização vetorial. Ao encurtar dados díspares para a mesma escala numérica, garantimos que nenhuma variável assuma um peso artificial que prejudique a avaliação das demais métricas comportamentais.

A capacidade preditiva é ancorada pelo componente Random Forest. O emprego simultâneo de múltiplas árvores de decisão dilui distorções individuais geradas por amostras viciadas. Isso minimiza violentamente a incidência do problema de overfitting. Por fim, injetamos a carga de dados higienizada e o motor instanciado da Random Forest no componente Test and Score. Ele executa a bateria de validação, fatiando a base, estudando blocos opacos e extraindo as métricas finais de performance que ditam se a inteligência instanciada está pronta ou não para o ambiente de produção da organização.



Interpretação dos Resultados Matemáticos

O estágio final do ciclo preditivo requer a interpretação crua da performance tática do modelo. Executamos essa auditoria em cima de dois parâmetros visuais determinísticos: a **Matriz de Confusão** e a **Curva ROC**.

A Matriz de Confusão expõe o boletim de acertos e falhas com absoluta transparência. O cruzamento numérico do histórico real contra as inferências sintéticas atestou uma alta resiliência do algoritmo. O índice de acerto na fatia de clientes orgânicos (True Negatives) atingiu 96,6%, cravando corretamente os usuários que não evadiriam. Na fatia de risco (True Positives), o motor identificou com 84,2% de precisão os usuários que realmente abandonaram o serviço. A assimetria baixa em falsos-negativos (3,3%) protege o negócio do erro mais letal: subestimar a bomba-relógio de um cliente prestes a ir embora.

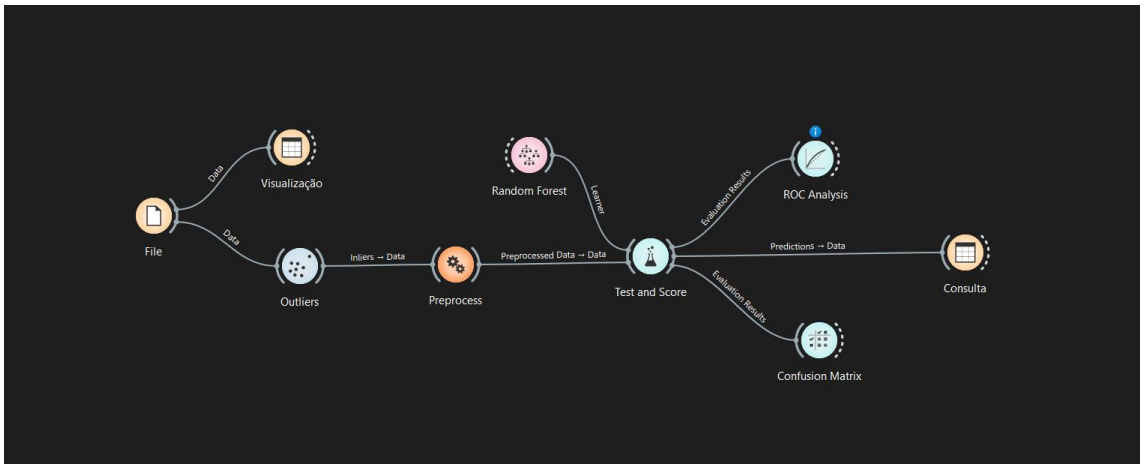
Essa eficácia bruta é endossada pelo diagnóstico gerado no ROC Analysis. A linha plotada próxima à extremidade superior esquerda do quadrante prova matematicamente a força separadora do modelo. A área sob a curva (**AUC**) tangencia a perfeição sistêmica, demonstrando que a separação entre clientes leais e desertores não é cinzenta quando balizada por metadados puros.

Para extirpar qualquer abstração ou "mágica" frequentemente associada a ferramentas visuais, isolamos a prova de conceito. Desenvolvi um script em Python para consumir as bibliotecas brutas do **Scikit-Learn** fora do escopo do **Orange**. A engenharia reversa extraiu a relevância vetorial utilizada na Random Forest: o atraso de faturas pesou impressionantes **48%** na decisão de rebaixamento para Churn, seguido pelo baixo engajamento (**15%**) e pelo ciclo de vida inicial curto (**15%**).

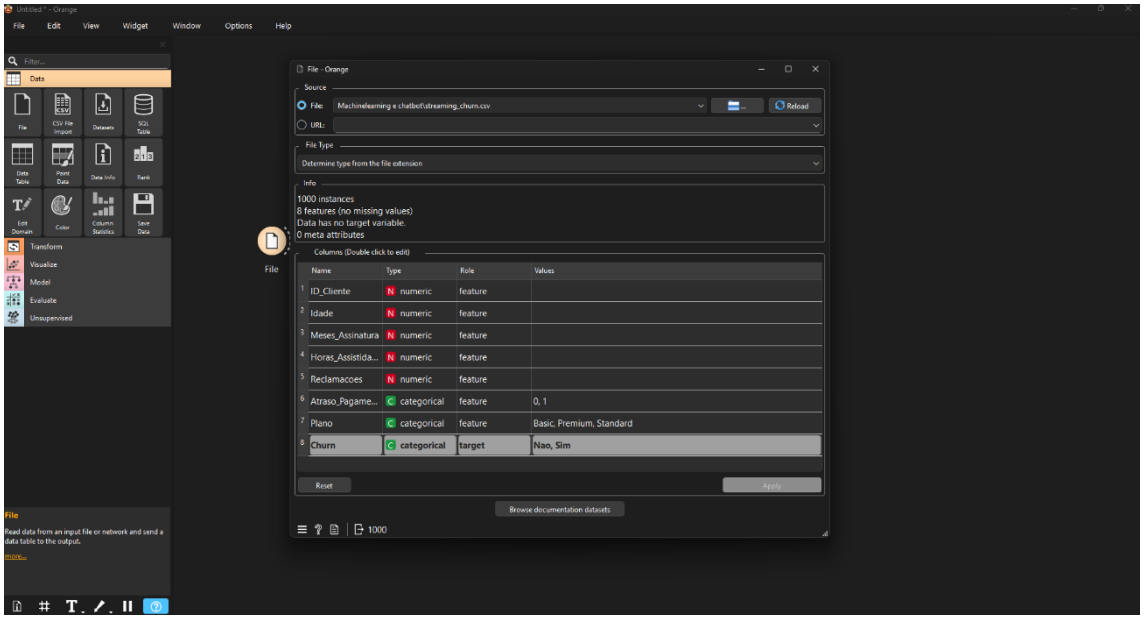
A consistência exata entre a matriz de validação cruzada gerada pela plataforma e os tensores expostos pelo código bruto liquida o ceticismo. O modelo encontrou gargalos reais baseados em lógica matemática inquestionável, pronta para ser traduzida em estratégia de retenção no ambiente corporativo real.

Fonte: Applied Predictive Modeling - ROC Curves and Performance Metrics

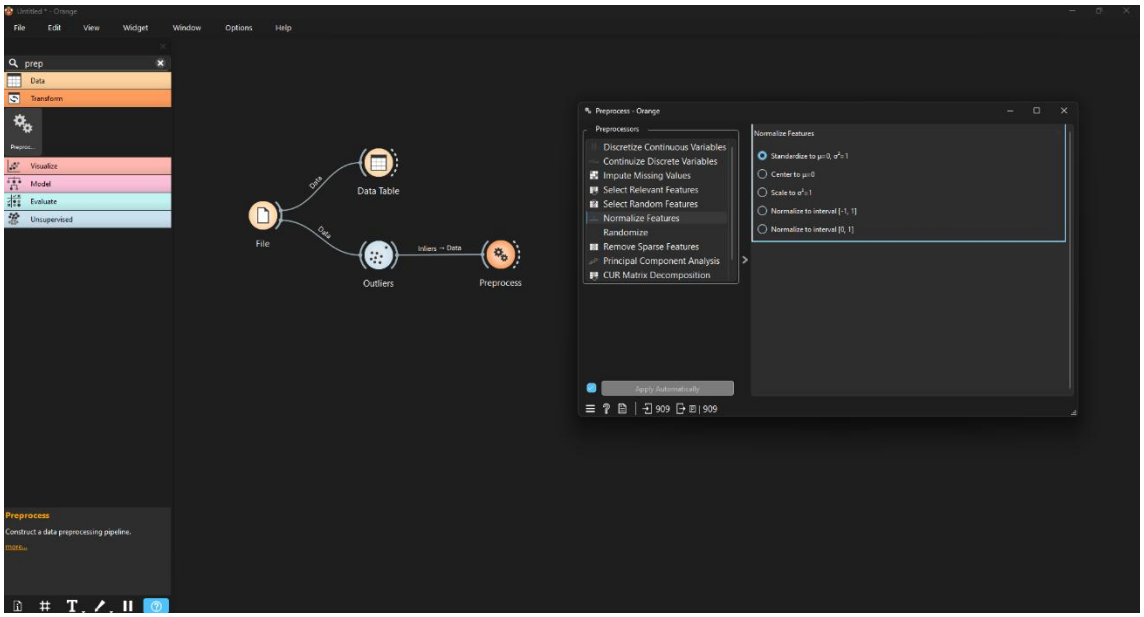
Visão macro do fluxo de machine learning construído. O pipeline demonstra a ingestão de dados (File), o tratamento de anomalias (Outliers), a normalização vetorial (Preprocess) e a injeção na rede de validação cruzada (Test and Score) impulsionada pelo algoritmo Random Forest. As saídas alimentam os nós de avaliação visual (ROC Analysis e Confusion Matrix).



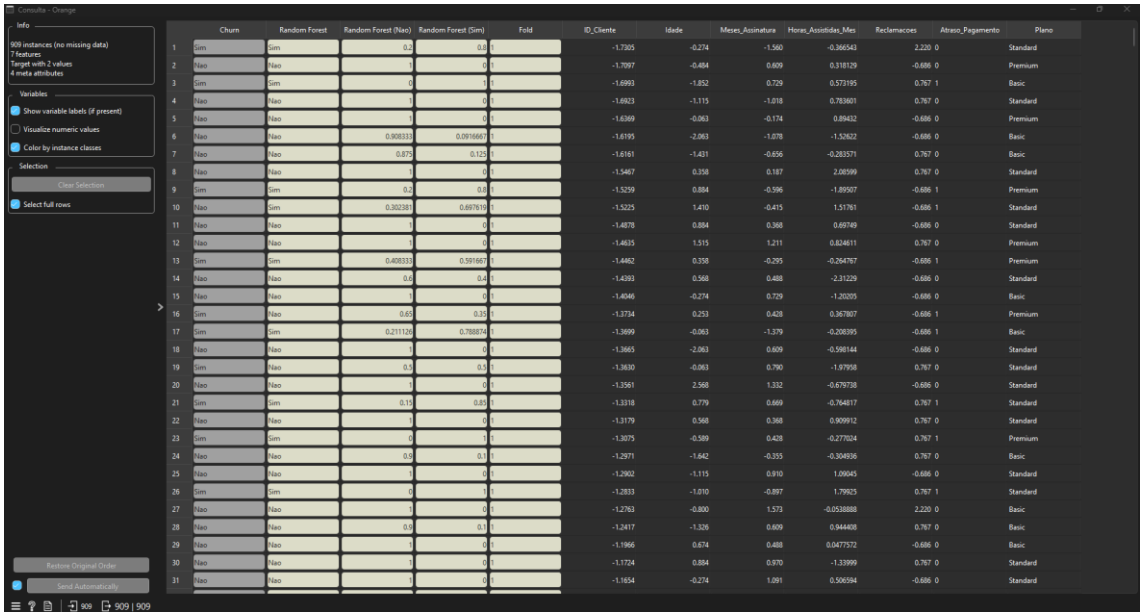
Tela de parametrização do nó File. A imagem comprova a importação correta das 8 variáveis comportamentais da base sintética e, crucialmente, a definição da coluna "Churn" como a variável alvo (target). Isso instruiu o algoritmo sobre o que exatamente ele deveria aprender a prever.



Detalhamento do nó Preprocess. A seleção da opção "Normalize Features" forçou todas as métricas (desde horas assistidas até idade) a compartilharem a mesma escala matemática (média 0, variância 1), impedindo que variáveis de grandeza maior esmagassem a relevância de métricas menores durante o treinamento.



Saída do nó Data Table acoplado ao Test and Score. A tabela cruza o Churn real do cliente com as probabilidades matemáticas calculadas pelo Random Forest (colunas Random Forest Não/Sim), demonstrando na prática como o algoritmo avaliou o risco de cada linha individual da base após a normalização.

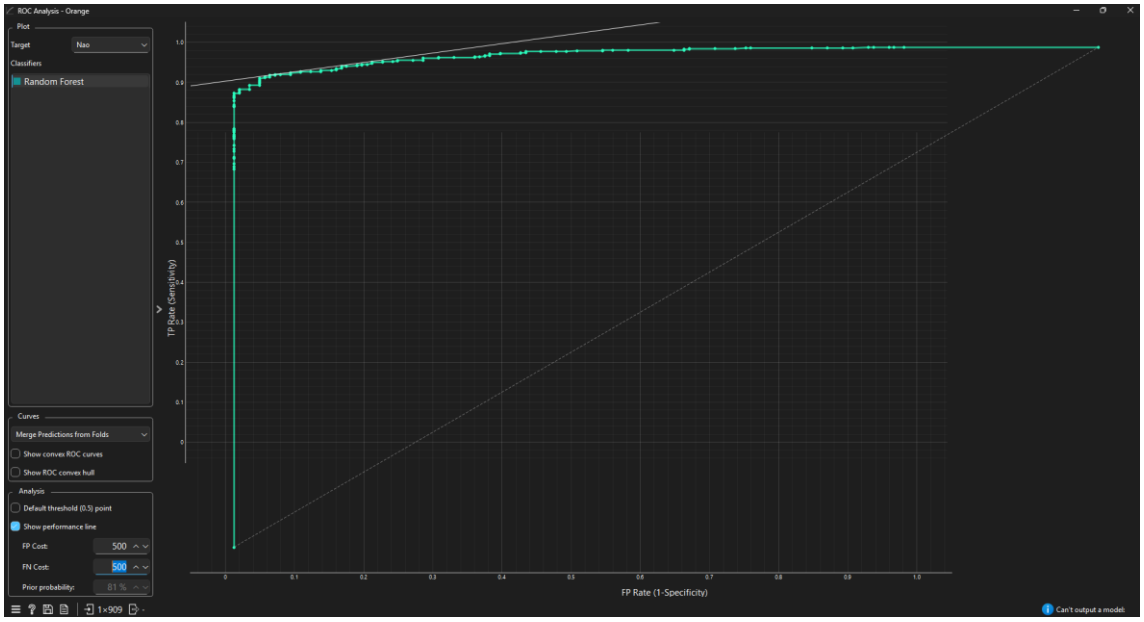


Diagnóstico de precisão do modelo preditivo exibido em volume total e proporção. O cruzamento atesta a alta resiliência do algoritmo: dos 909 registros validados, o modelo cravou corretamente 713 verdadeiros negativos (96,7% de precisão na identificação de clientes retidos) e 145 verdadeiros positivos (84,3% de precisão na detecção de clientes que evadiram). O volume irrisório de falsos-negativos (apenas 24 casos, ou 3,3%) atesta a confiabilidade matemática do motor em não subestimar os usuários com real risco de cancelamento. (OBS: fiz vários testes, por isso os valores podem variar um pouco de teste para teste.)

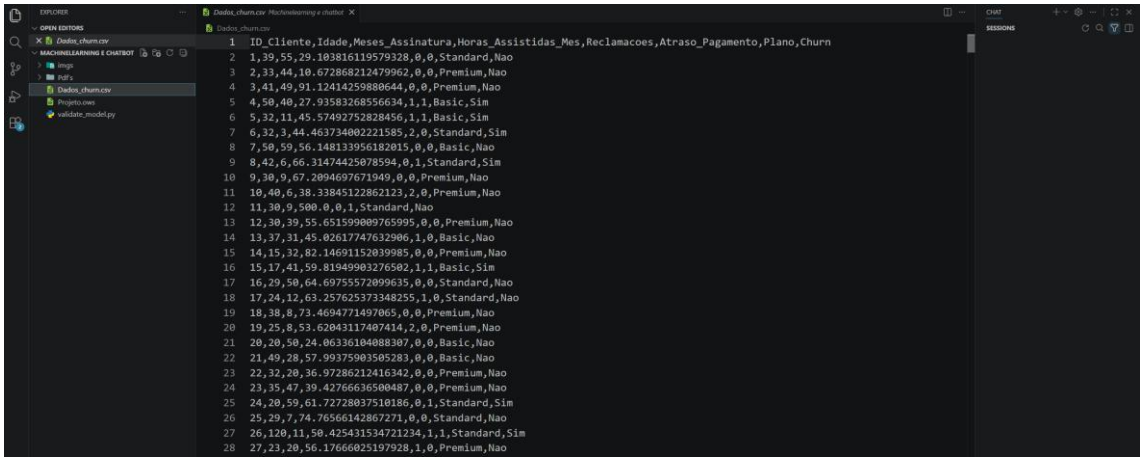
Actual	Predicted Nao	Predicted Sim	Σ
Nao	96.7 %	15.7 %	740
Sim	3.3 %	84.3 %	169
Σ	737	172	909

Actual	Predicted Nao	Predicted Sim	Σ
Nao	713	27	740
Sim	24	145	169
Σ	737	172	909

Gráfico de performance da classificação binária. A curva verde fortemente tracionada para o canto superior esquerdo (alta sensibilidade e baixa taxa de falso positivo) comprova graficamente que o modelo possui uma excelente capacidade de distinguir entre clientes que vão cancelar e clientes que vão permanecer na plataforma.

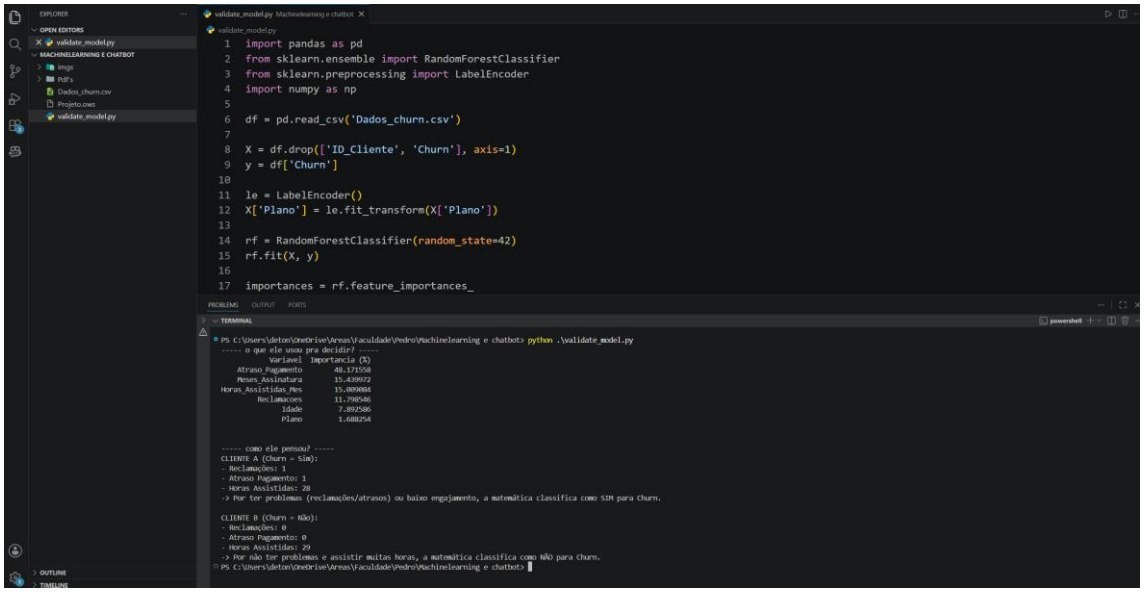


*Visão interna do arquivo **dados_churn.csv** que usei para a análise. A estrutura tabular dos dados e o cabeçalho mapeando as variáveis comportamentais isoladas (Idade, Horas Assistidas, Reclamações, Atraso de Pagamento). Este é o insumo numérico bruto antes de qualquer tratamento preditivo da máquina.*



```
ID_Cliente,Idade,Meses_Assinatura,Horas_Assistidas_Mes,Reclamacoes,Atraso_Pagamento,Plano,Churn
1,39,55,29.103816119579328,0,0,Standard,Nao
2,33,44,10.672868212479962,0,0,Premium,Nao
3,41,49,91.12414259880644,0,0,Premium,Nao
4,50,40,27.93583268556634,1,1,Basic,Sim
5,32,11,45.57492752828456,1,1,Basic,Sim
6,32,3,44.463734002221585,2,0,Standard,Sim
7,50,59,56.148133956182015,0,0,Basic,Nao
8,42,6,66.31474425078594,0,1,Standard,Sim
9,30,9,67.2094697671949,0,0,Premium,Nao
10,40,6,38.33845122862123,2,0,Premium,Nao
11,30,9,500.0,0,1,Standard,Nao
12,30,39,55.651599089765995,0,0,Premium,Nao
13,37,31,45.02617747632906,1,0,Basic,Nao
14,15,32,82.14691152039985,0,0,Premium,Nao
15,17,41,59.81949903276502,1,1,Basic,Sim
16,29,50,64.69755572099635,0,0,Standard,Nao
17,24,12,63.257625373348255,1,0,Standard,Nao
18,38,8,73.4694771497065,0,0,Premium,Nao
19,25,8,53.62043117407414,2,0,Premium,Nao
20,20,50,24.06336104088307,0,0,Basic,Nao
21,49,28,57.99375903505283,0,0,Basic,Nao
22,32,20,36.97286212416342,0,0,Premium,Nao
23,35,47,39.42766636500487,0,0,Premium,Nao
24,20,59,61.72728037510186,0,1,Standard,Sim
25,29,7,74.76566142867271,0,0,Standard,Nao
26,120,11,50.425431534721234,1,1,Standard,Sim
27,23,20,56.17666025197928,1,0,Premium,Nao
```

Execução do algoritmo Random Forest em código puro, fora da interface visual do Orange, para auditar a lógica interna da Inteligência Artificial. O terminal atesta matematicamente a relevância vetorial das variáveis (onde o Atraso de Pagamento lidera com 48,1% do peso de decisão) e simula a interpretação exata do modelo sobre dois clientes reais (A e B). Isso extirpa o viés de "caixa-preta" do software e comprova a integridade técnica da solução.



```
import pandas as pd
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import LabelEncoder
import numpy as np

df = pd.read_csv('Dados_churn.csv')

X = df.drop(['ID_Cliente', 'Churn'], axis=1)
y = df['Churn']

le = LabelEncoder()
X['Plano'] = le.fit_transform(X['Plano'])

rf = RandomForestClassifier(random_state=42)
rf.fit(X, y)

importances = rf.feature_importances_
```

```
PS C:\Users\deton\OneDrive\Áreas\Faculdade\Pedro\Machinelearning e chatbot> python .\validate_model.py
----- o que ele usou pra decidir? -----
             Variavel  Importancia (%)
    Atraso_Pagamento        48.171558
      Meses_Assinatura        15.439972
Horas_Assistidas_Mes        15.089084
          Reclamacoes        11.798546
                Idade         7.892586
                Plano         1.608254


----- como ele pensou? -----
CLIENTE A (Churn = Sim):
- Reclamações: 1
- Atraso Pagamento: 1
- Horas Assistidas: 28
-> Por ter problemas (reclamações/atrasos) ou baixo engajamento, a matemática classifica como SIM para Churn.

CLIENTE B (Churn = Não):
- Reclamações: 0
- Atraso Pagamento: 0
- Horas Assistidas: 29
-> Por não ter problemas e assistir muitas horas, a matemática classifica como NÃO para Churn.
PS C:\Users\deton\OneDrive\Áreas\Faculdade\Pedro\Machinelearning e chatbot>
```